

МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ
УЧРЕЖДЕНИЕ ОБРАЗОВАНИЯ
«БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ ИНФОРМАТИКИ И
РАДИОЭЛЕКТРОНИКИ»
Факультет компьютерных систем и сетей
Кафедра программного обеспечения информационных технологий

ОТЧЕТ
по лабораторной работе № 2
по дисциплине «Методы машинного обучения»
на тему: «Разведочный анализ данных, обработка пропусков и выбросов,
конструирование признаков и масштабирование»

Выполнил(а):
студент(ка) гр. 351002
Валинский А. С.

Проверил:
преподаватель
Лебедевич А. В.

Минск 2026

1 ЦЕЛЬ РАБОТЫ

Целью выполнения лабораторной работы является:

1. Освоение базовой методологии разведочного анализа данных (*Exploratory Data Analysis, EDA*) с использованием программных средств библиотеки `pandas` и пакетов визуализации `matplotlib` и `seaborn`.
2. Изучение статистических методов первичного анализа данных, обнаружения пропущенных значений и освоение способов их корректного устранения или восстановления (импутации).
3. Получение практических навыков выявления аномальных значений (выбросов) с помощью статистического критерия межквартильного размаха (*Interquartile Range, IQR*) и диаграмм размаха («ящик с усами», *BoxPlot*).
4. Практическое освоение методов конструирования новых признаков (*Feature Engineering*) и кодирования категориальных переменных (бинаризация, порядковое кодирование *Ordinal Encoding*, прямое кодирование *One-Hot Encoding*).
5. Изучение математических основ масштабирования числовых данных (нормализация *MinMaxScaler*, стандартизация *StandardScaler*) и анализ трансформации формы их распределений.

2 КРАТКИЕ ТЕОРЕТИЧЕСКИЕ СВЕДЕНИЯ

2.1 Разведочный анализ данных и описательная статистика

Разведочный анализ данных представляет собой фундаментальный начальный этап исследования, целью которого является детальное изучение внутренней структуры датасета, распределений признаков, выявление скрытых взаимосвязей, закономерностей и аномалий перед построением прогностических моделей.

Описательная статистика подразделяется на две ключевые категории: меры центральной тенденции и меры рассеяния. Меры центральной тенденции характеризуют типичное значение распределения:

- **Среднее арифметическое (μ)** — сумма всех значений, деленная на их объем; высокочувствительно к экстремальным выбросам.
- **Медиана (Me)** — значение, делящее упорядоченную выборку на две равные части; является робастной метрикой, устойчивой к аномалиям.
- **Мода (Mo)** — наиболее часто встречающееся значение в выборке, применимое как к числовым, так и к категориальным признакам.

Меры рассеяния описывают степень вариативности данных относительно центрального значения. К ним относятся дисперсия σ^2 , стандартное отклонение σ и квантили. Квантилями порядка $p \in (0, 1)$ называют значения, отсекающие долю p отсортированной выборки. Первый квартиль Q_1 соответствует уровню 25 %, медиана Q_2 — уровню 50 %, а третий квартиль Q_3 — уровню 75 %. Разность между третьим и первым квартилями определяет межквартильный размах:

$$IQR = Q_3 - Q_1 . \quad (1)$$

2.2 Обнаружение и методы обработки пропусков

Пропущенные значения (NaN, None) возникают в результате сбоев датчиков, ошибок ручного ввода данных либо объединения неоднородных таблиц. Первичная диагностика осуществляется с помощью методов `isna()`, `info()` и визуализируется тепловой картой матричной маски пропусков.

Согласно общепринятой методологии предварительной обработки данных:

1. Если доля пропусков в столбце превышает 70 %, данный столбец признается малоинформативным и подлежит полному исключению из анализа.
2. При малом проценте пропусков для непрерывных числовых признаков применяется заполнение медианой (в условиях асимметрии) либо средним значением.

3. Для категориальных и дискретных признаков пропуски восстанавливаются модой (наиболее распространенной категорией).
4. В ряде задач оправдано создание дополнительного бинарного признака-индикатора факта наличия пропуска.

2.3 Статистическая идентификация и устранение выбросов

Выбросом (аномалией) называется наблюдение, значительно отклоняющееся от общего распределения значений выборки. Для выявления выбросов строится диаграмма «ящик с усами» (*BoxPlot*). В классическом подходе Тьюки границы допустимого диапазона значений определяются по формулам:

$$X_{\text{lower}} = Q_1 - 1,5 \cdot IQR, \quad X_{\text{upper}} = Q_3 + 1,5 \cdot IQR. \quad (2)$$

Значения, лежащие за пределами интервала $[X_{\text{lower}}, X_{\text{upper}}]$, квалифицируются как статистические выбросы. В анализе данных для устранения аномалий применяют либо их физическое удаление из обучающей выборки, либо замену граничным значением/медианой, либо смягчение нелинейными монотонными функциями (логарифмированием).

2.4 Конструирование и кодирование признаков

Конструирование признаков (*Feature Engineering*) направлено на извлечение новых информативных предикторов путем комбинирования исходных полей на основе предметной логики.

Алгоритмы машинного обучения оперируют числовыми тензорами, поэтому категориальные признаки требуют предварительного кодирования:

- **Бинарное кодирование:** преобразование категорий с двумя альтернативами в множество $\{0, 1\}$.
- **Порядковое кодирование (*Ordinal Encoding*):** сопоставление категориям, обладающим естественной иерархией рангов ($Low < Medium < High$), последовательных целых чисел $\{0, 1, 2, \dots\}$.
- **Прямое унитарное кодирование (*One-Hot Encoding, OHE*):** преобразование номинального признака с k категориями в $k - 1$ бинарных столбцов с исключением первого базового уровня (`drop_first=True`) для предотвращения линейной зависимости (мультиколлинеарности).

2.5 Масштабирование данных: нормализация и стандартизация

Признаки с большим абсолютным диапазоном значений доминируют в функциях ошибки градиентных методов и алгоритмов, основанных на вычислении евклидовых расстояний (k -NN, SVM, нейронные сети). Масштабирование нивелирует данный дисбаланс.

Min-Max нормализация линейно сжимает диапазон значений признака в заданный интервал, как правило $[0, 1]$:

$$X_{\text{norm}} = \frac{X - X_{\min}}{X_{\max} - X_{\min}}. \quad (3)$$

Стандартизация (Z-score) центрирует данные относительно выборочного среднего μ и масштабирует к единичному стандартному отклонению σ :

$$z = \frac{X - \mu}{\sigma}, \quad \mathbb{E}[z] = 0, \quad \mathbb{D}[z] = 1. \quad (4)$$

Стандартизация сохраняет форму исходного распределения и менее чувствительна к экстремальным значениям выборки.

3 ФОРМУЛИРОВКА ИНДИВИДУАЛЬНОГО ЗАДАНИЯ

Для выполнения лабораторной работы выбран набор данных `StudentPerformanceFactors.csv`, содержащий комплексные социально-демографические, учебные и поведенческие характеристики учащихся средней школы, а также их итоговые экзаменационные оценки (`Exam_Score`).

Индивидуальное задание включает четыре последовательных этапа:

1. **Задание 1.** Импортировать набор данных с помощью библиотеки `pandas`, изучить структуру таблицы, объем выборки и типы полей.
2. **Задание 2.** Проверить данные на пропуски и наличие аномальных значений с использованием статистических методов и графических средств (*BoxPlot*, тепловые карты). Заполнить пропуски и устранить выбросы по правилу межквартильного размаха. Выполнить повторную контрольную визуализацию.
3. **Задание 3.** Сгенерировать не менее двух новых признаков на основе предметной логики предметной области. Выполнить кодирование категориальных признаков (бинаризация, порядковое кодирование *Ordinal Encoding*, прямое *One-Hot* кодирование).
4. **Задание 4.** Выполнить масштабирование непрерывных числовых признаков (нормализацию `MinMaxScaler` и стандартизацию `StandardScaler`). Провести сравнительный анализ гистограмм распределения до и после масштабирования.

4 КОД РЕШЕНИЯ ИНДИВИДУАЛЬНОГО ЗАДАНИЯ

Ниже приведен полный программный код решения заданий лабораторной работы, разработанный в среде Jupyter Notebook.

Импорт библиотек и загрузка датасета (Задание 1)

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# Задание 1: Загрузка набора данных
df = pd.read_csv('../data/StudentPerformanceFactors.csv')
print("Тип загруженного объекта:", type(df))
print("Размерность датасета (строк, столбцов):", df.shape)
print("\nПервые строки датасета:")
print(df.head())
```

Диагностика

```
# 1. Диагностика пропусков
null_counts = df.isna().sum()
print("Количество пропусков по признакам:\n", null_counts[null_counts > 0])

# Визуализация исходного распределения с выбросами
plt.figure(figsize=(8, 4))
sns.boxplot(x=df['Hours_Studied'], color='skyblue')
plt.title("BoxPlot для Hours_Studied (до очистки)")
plt.show()

# 2. Заполнение пропусков модой для категориальных признаков
columns_with_nulls = ['Teacher_Quality', 'Parental_Education_Level', 'Distance_from_Home']
for col in columns_with_nulls:
    mode_value = df[col].mode()[0]
    df[col] = df[col].fillna(mode_value)
    print(f"Столбец '{col}' заполнен значением: {mode_value}")

print("Всего пропусков в таблице после импутации:", df.isna().sum().sum())

# 3. Устранение выбросов по методу межквартильного размаха (IQR)
print("\nРазмер датасета ДО удаления выбросов:", df.shape)
for col in ['Hours_Studied', 'Exam_Score']:
    Q1 = df[col].quantile(0.25)
    Q3 = df[col].quantile(0.75)
    IQR = Q3 - Q1
    lower_bound = Q1 - 1.5 * IQR
    upper_bound = Q3 + 1.5 * IQR
    df = df[(df[col] >= lower_bound) & (df[col] <= upper_bound)]
```

```

print("Размер датасета ПОСЛЕ удаления выбросов:", df.shape)

# 4. Графическая верификация отсутствия пропусков и выбросов
plt.figure(figsize=(10, 3))
sns.heatmap(df.isna(), cbar=False, yticklabels=False, cmap
='viridis')
plt.title("Графическая проверка: пропуски полностью отсутств
уют")
plt.show()

plt.figure(figsize=(8, 3))
sns.boxplot(x=df['Hours_Studied'], color='skyblue')
plt.title("Графическая проверка: BoxPlot для Hours_Studied Б
ЕЗ выбросов")
plt.show()

```

Конструирование признаков и кодирование категорий (Задание 3)

```

# 1. Feature Engineering: генерация новых информативных при
знаков
# Признак 1: Общая учебная нагрузка (самостоятельные часы +
репетитор с весом 1.5)
df['Total_Study_Effort'] = (df['Hours_Studied'] + (df['Tutor
ing_Sessions'] * 1.5)).round(1)

# Признак 2: Ожидаемый потенциал успеваемости (прошлые балл
ы, взвешенные по посещаемости)
df['Attendance_Weighted_Score'] = ((df['Attendance'] / 100)
* df['Previous_Scores']).round(2)

# Признак 3: Баланс учебы и сна (доля часов учебы относител
ьно недельного объема сна)
df['Study_to_Sleep_Ratio'] = (df['Hours_Studied'] / (df['Sle
ep_Hours'] * 7)).round(3)

print("Примеры значений сгенерированных признаков:")
print(df[['Hours_Studied', 'Tutoring_Sessions', 'Total_Study
_Effort',
          'Attendance_Weighted_Score', 'Study_to_Sleep_Rati
o']].head())

# 2. Бинарное кодирование (0 / 1)
binary_cols_yes_no = ['Extracurricular_Activities', 'Interne
t_Access', 'Learning_Disabilities']
for col in binary_cols_yes_no:
    df[col] = df[col].map({'Yes': 1, 'No': 0})
df['School_Type'] = df['School_Type'].map({'Public': 0, 'Pri
vate': 1})
df['Gender'] = df['Gender'].map({'Male': 0, 'Female': 1})

# 3. Порядковое кодирование (Ordinal Encoding)
ordinal_mappings = {
    'Parental_Involvement': {'Low': 0, 'Medium': 1, 'High':
2},

```

```

    'Access_to_Resources': {'Low': 0, 'Medium': 1, 'High':
2},
    'Motivation_Level': {'Low': 0, 'Medium': 1, 'High':
2},
    'Family_Income': {'Low': 0, 'Medium': 1, 'High':
2},
    'Teacher_Quality': {'Low': 0, 'Medium': 1, 'High':
2},
    'Distance_from_Home': {'Near': 0, 'Moderate': 1, 'Fa
r': 2}
}
for col, mapping in ordinal_mappings.items():
    df[col] = df[col].map(mapping)

# 4. One-Hot Encoding для номинальных категорий
nominal_cols = ['Peer_Influence', 'Parental_Education_Leve
l']
df = pd.get_dummies(df, columns=nominal_cols, drop_first=True,
dtype=int)

print("\nРазмерность таблицы после кодирования признаков:",
df.shape)

```

4) Масштабирование данных и визуализация распределений (Задание 4)

```

from sklearn.preprocessing import MinMaxScaler, StandardScaler

# Разделение матрицы признаков и целевой переменной
X = df.drop(columns=['Exam_Score'])
y = df['Exam_Score']

numeric_features = [
    'Hours_Studied', 'Attendance', 'Sleep_Hours', 'Previous_
Scores',
    'Tutoring_Sessions', 'Physical_Activity', 'Total_Study_E
ffort',
    'Attendance_Weighted_Score', 'Study_to_Sleep_Ratio'
]

# 1. Нормализация (MinMaxScaler: сжатие в [0, 1])
min_max_scaler = MinMaxScaler()
X_normalized = X.copy()
X_normalized[numeric_features] = min_max_scaler.fit_transfor
m(X[numeric_features])
print("Параметры нормализованных признаков:")
print(X_normalized[numeric_features].describe().loc[['min',
'max']])

# 2. Стандартизация (StandardScaler:  $\mu \sim 0$ ,  $\sigma \sim 1$ )
std_scaler = StandardScaler()
X_standardized = X.copy()
X_standardized[numeric_features] = std_scaler.fit_transform
(X[numeric_features])

```

```

print("\nПараметры стандартизированных признаков:")
print(X_standardized[numeric_features].describe().round(3).loc[['mean', 'std']])

# 3. Визуальное сравнение распределений
fig, axes = plt.subplots(1, 3, figsize=(15, 4))
sns.histplot(X['Previous_Scores'], kde=True, ax=axes[0], color='royalblue', bins=20)
axes[0].set_title('Исходный признак\n(Previous_Scores: шкала [40, 100])')
sns.histplot(X_normalized['Previous_Scores'], kde=True, ax=axes[1], color='forestgreen', bins=20)
axes[1].set_title('Нормализация (MinMaxScaler)\n(Шкала строга [0, 1])')
sns.histplot(X_standardized['Previous_Scores'], kde=True, ax=axes[2], color='crimson', bins=20)
axes[2].set_title('Стандартизация (StandardScaler)\n(Центр 0, разброс [-3, 3])')
plt.tight_layout()
plt.show()

```

5 РЕЗУЛЬТАТЫ ВЫПОЛНЕНИЯ ИНДИВИДУАЛЬНОГО ЗАДАНИЯ

Разведочный анализ и преобразование данных выполнены на выборке из 6607 записей с 20 признаками. Ниже приведены пошаговые результаты выполнения каждого этапа.

На рисунке 1 представлена тепловая карта пропущенных значений в исходном датасете до применения процедур очистки.




Рисунок 1 – Тепловая карта наличия пропусков в исходном датасете

Анализ пропусков показал наличие незаполненных ячеек в трех столбцах категориального типа: `Teacher_Quality` — 78 пропусков (1{,}18 %), `Parental_Education_Level` — 90 пропусков (1{,}36 %), `Distance_from_Home` — 67 пропусков (1{,}01 %). Суммарное количество пропусков составило 235 ячеек. Так как доля пропусков в каждом столбце существенно меньше критического порога в 70 %, столбцы сохранены и заполнены наиболее часто встречающимися модальными значениями: 'Medium' для качества преподавания, 'High School' для уровня образования родителей и 'Near' для удаленности от дома.

На рисунке 2 приведены диаграммы размаха (*BoxPlot*) для числовых признаков объема учебных часов `Hours_Studied` и целевого экзаменационного балла `Exam_Score` до удаления выбросов.




Рисунок 2 – Диаграммы размаха с визуализацией выбросов до очистки

Расчет межквартильного размаха позволил установить следующие границы допустимых значений:

- для `Hours_Studied`: $Q_1 = 16,0$, $Q_3 = 24,0$, $IQR = 8,0$, диапазон без аномалий $[4,0, 36,0]$ ч;
- для `Exam_Score`: $Q_1 = 65,0$, $Q_3 = 69,0$, $IQR = 4,0$, диапазон без аномалий $[59,0, 75,0]$ баллов.

В результате фильтрации выборка сократилась с 6607 до 6473 строк (удалено 134 строки с аномальными экстремумами).

На рисунке 3 представлена графическая верификация качества очистки: монолитная тепловая карта подтверждает отсутствие незаполненных значений, а обновленные диаграммы размаха демонстрируют ликвидацию точек-выбросов за усами распределения.




Рисунок 3 – Контрольная проверка структуры данных после очистки пропусков и выбросов

На этапе конструирования признаков были синтезированы три новых поля:

- `Total_Study_Effort` — совокупная учебная нагрузка с весовым учетом индивидуальных занятий с репетитором;
- `Attendance_Weighted_Score` — накопленный потенциал успеваемости, отражающий прошлые академические результаты с поправкой на регулярность посещения;

– Study_to_Sleep_Ratio — показатель сбалансированности режима дня студента.

После выполнения бинаризации 5 бинарных характеристик, порядкового ранжирования 6 признаков со шкалой от 0 до 2 и прямого *One-Hot* кодирования номинальных полей размерность матрицы признаков увеличилась до 25 столбцов, а все категориальные сущности были преобразованы в числовой формат.

На рисунке 4 приведена матрица парных корреляций Пирсона для сконструированных признаков и целевого экзаменационного балла.




Рисунок 4 – Матрица корреляций признаков с итоговым экзаменационным баллом

Как следует из полученной матрицы, сгенерированные признаки обладают выраженной корреляцией с целевой переменной Exam_Score: признак Attendance_Weighted_Score имеет коэффициент корреляции 0,57, признак совокупной нагрузки Total_Study_Effort — 0,53, а отношение учебы ко сну Study_to_Sleep_Ratio — 0,39. Наибольшее прямое влияние на итоговый балл оказывает посещаемость занятий ($r = 0,68$) и количество часов самостоятельной подготовки ($r = 0,49$).

На рисунке 5 представлены результаты сравнительного визуального анализа формы распределения признака Previous_Scores в исходном виде, после нормализации MinMaxScaler и после стандартизации StandardScaler.




Рисунок 5 – Сравнение гистограмм распределения до и после масштабирования

Анализ гистограмм показывает, что процедура нормализации строго трансформирует шкалу в компактный интервал $[0, 0, 1, 0]$, сохраняя исходную форму плотности вероятности. Стандартизация центрирует среднее значение признака точно в начале координат ($\mu \approx 0,000$) с единичным стандартным отклонением ($\sigma = 1,000$), приводя числовые шкалы различных предиктивных факторов к эквивалентной дисперсии, что обеспечивает оптимальную сходимость последующих моделей машинного обучения.

6 ВЫВОДЫ

В ходе выполнения лабораторной работы № 2 получены следующие практические результаты:

1. Освоена методика разведочного анализа данных (*EDA*) с помощью библиотек `pandas`, `matplotlib` и `seaborn` на примере набора данных успеваемости учащихся.
2. Проведена детальная диагностика качества данных: выявлено 235 пропущенных значений в трех категориальных столбцах, которые были корректно заполнены модальными значениями без потери информативности.
3. На основе статистического анализа межквартильного размаха (*IQR*) обнаружены и удалены 134 строки с экстремальными аномальными значениями, что стабилизировало выборку и предотвратило смещение будущих оценок модели.
4. Сконструированы три предметно обоснованных признака (`Total_Study_Effort`, `Attendance_Weighted_Score`, `Study_to_Sleep_Ratio`), показавшие высокие коэффициенты линейной корреляции с целевым признаком (до $r = 0,57$).
5. Проведено комплексное кодирование категориальных данных (бинарное, порядковое и прямое унитарное), в результате чего все 25 признаков таблицы приведены к числовому формату.
6. Выполнено масштабирование непрерывных числовых признаков методами `MinMaxScaler` и `StandardScaler`; графически подтверждено приведение шкал к каноническим диапазонам при сохранении топологии исходных плотностей распределения.